Definizione ed Implementazione di un Sistema di Raccomandazione Distribuito per film e Modellazione di Eventi Complessi

Prof. Ing. Tommaso di Noia Prof.ssa Marina Mongiello Dott. Francesco Nocera Mauro Losciale Pietro Tedeschi



Logica e Intelligenza Artificiale Ingegneria del Software Avanzata Laurea Magistrale in Ingegneria Informatica Politecnico di Bari A.A 2015 - 2016

Indice

ını	troduzione	1	
1	Stato dell'arte 1.1 Introduzione ai sistemi CEP 1.2 Sistemi di Raccomandazione 1.2.1 Metriche di Valutazione 1.2.2 Introduzione alla Matrix Factorization 1.3 Introduzione al Data Stream Processing 1.4 Il paradigma Publish-Subscribe 1.5 Il pattern Facade 1.6 Il pattern Singleton 1.7 Il pattern Model-View-Controller (MVC) 1.8 La tecnologia WebSocket	2 3 6 7 8 8 9 10 10	
2	Soluzione proposta 2.1 La libreria Spark 2.1.1 Spark Streaming 2.1.2 Spark MLlib 2.1.3 Spark SQL 2.2 Apache Kafka 2.2.1 Integrazione con Spark Streaming 2.3 Il framework Node.js 2.4 Angular.js	13 14 15 15 15 17 17	
3	Analisi e progettazione della soluzione proposta 3.1 Modello software	19 19 21 25	
BII	Bibliografia		
5	Sorgenti	27	
Аp	ppendice A Sorgenti Spark	27	
Αp	Appendice B Sorgenti Node.is		

Introduzione

La crescente diffusione dei contenuti digitali e la proliferazione pervasiva dei dispositivi tecnologici, hanno aperto un nuovo scenario innovativo alla costruzione di sistemi che potessero seguire in qualche modo le scelte di un utente. I **sistemi di raccomandazione** infatti, sono degli strumenti che suggeriscono in modo personalizzato i prodotti utili che potrebbero incuriosire un utente, in base ai propri interessi. L'elenco degli elementi in output è il risultato di un processo decisionale, che ha l'obiettivo di dedurre quali sono le preferenze dell'utente ed aiutarlo a scegliere il prodotto a lui più indicato.

I sistemi di raccomandazione, coinvolgono settori multidisciplinari che vanno dall'interazione uomo-macchina, all'intelligenza artificiale, dalla sicurezza informatica, al supporto decisionale. Esempi cardini di questi sistemi sono *Google News* per le notizie, *Netflix* per i film, *Amazon* per l'e-commerce, *Last.fm* per la musica.

Il seguente tema d'anno, ha lo scopo di costruire un sistema di raccomandazione distribuito, utilizzabile con un'interfaccia web, che sia in grado di analizzare lo stream dati in input, gestendo gli eventi complessi mediante query continue sul flusso informativo. Il sistema di raccomandazione consentirà di votare un numero di film che sia strettamente maggiore di tre, selezionando i contenuti votati con un rate superiore o uguale a quattro, al fine di raccomandare i film non ancora visti, che si avvicinano di più ai gusti dell'utente.

Il sistema progettato ed implementato a livello di middleware per il collaborative filtering, utilizza le seguenti tecnologie: **Apache Spark**, **Apache Kafka**, **Node.js**, **Angular.js**. I linguaggi di programmazione usati sono **Scala** e **Javascript**.

Il presente lavoro è organizzato nel modo seguente:

- Nel **Capitolo 1**, è stato descritto lo stato dell'arte relativo ai sistemi CEP, sistemi di raccomandazione, Stream Processing, i pattern utilizzati per la progettazione del software e la tecnologia websocket per il developing della piattaforma web, evidenziandone gli aspetti principali.
- Nel **Capitolo 2**, si affronta la discussione sulla soluzione proposta, descrivendo nel dettaglio i framework e le librerie utilizzate.
- Nel **Capitolo 3**, si descrive l'analisi e la progettazione della soluzione proposta, illustrandone l'architettura del sistema, l'architettura del software, e le particolarità inerenti alla configurazione del funzionamento del sistema.
- Il **Capitolo 4**, è dedicato alla descrizione delle conclusioni e possibili sviluppi futuri con un'analisi dei vantaggi e dei miglioramenti relativi al lavoro svolto.
- Il **Capitolo 5**, infine contiene i sorgenti dell'applicativo realizzato.

1 Stato dell'arte

1.1 Introduzione ai sistemi CEP

L'incremento dei dispositivi interconnessi e delle applicazioni distribuite, richiede un'elaborazione continua del flusso dati. Esempi di tali applicazioni, vanno dal traffico generato dalle Wireless Sensor Networks (WSN) al flusso dati relativo agli indici finanziari, dal monitoraggio stradale alla Clickstream Analysis.

Un sistema ad eventi complessi o **Complex Event Processing** (CEP), modella il flusso informativo dei dati, visualizzando gli elementi come notifiche di ciò che sta accadendo nel mondo esterno. I dati vengono rilevati e filtrati utilizzando dei pattern (oppure le *processing rules*), i quali hanno il compito di rappresentare il modello di riferimento con l'informazione da rilevare, per poi farla pervenire alle rispettive parti (ad esempio, i dispositivi che effettuano una sottoscrizione ad un determinato topic nel paradigma *publish-subscribe*). L'obiettivo di un sistema CEP consiste nell'identificare eventi significativi e rispondere ad essi nel più breve tempo possibile. Un pattern o una regola, può essere definita mediante un linguaggio basato su query, il cosiddetto **Event Query Language**.




Figura 1: Architettura di un Sistema CEP [9]

Gli **Event Query Languages** possono essere raggruppati in tre categorie: *Composition Operators, Data Stream Query Languages e Production Rules*. I **Composition Operators** identificano gli eventi complessi partendo dalla composizione dei singoli eventi, utilizzando operatori quali congiunzione, negazione o di sequenza per la costruzione delle espressioni. Esempi rilevanti sono IBM Active Middleware Technology e ruleCore.

I **Data Stream Query Languages** sono basati sul linguaggio SQL; gli stream di dati sono semplicemente tuple convertite per database relazionali, in modo che si possano eseguire query SQL su di esse. E' utile citare i seguenti approcci: CQL, Coral8, StreamBase, Aleri, Esper e così via.

Le **Production Rules** specificano le azioni che devono essere eseguite quando il sistema si trova in determinati stati; non è un linguaggio ad eventi, ma costituisce un approccio importante nei sistemi CEP. Un esempio pratico è TIBCO Business Events.

Un altro fattore importante da considerare è il tempo. Sono due le parti da tener presente quando si parla del tempo: il *tempo della finestra* ed il *tempo dell'evento* informativo. Il tempo della finestra mostra gli eventi che vengono esaminati in un determinato intervallo. Il tempo dell'evento invece, porta con se informazioni relative alla data, ora di rilevazione, tempo di transizione, ed intervallo di elaborazione.

I contributi relativi ai sistemi CEP, arrivano da diverse comunità, a partire da quelle che si occupano di sistemi distribuiti, automazione industriale, sistemi di controllo, monitoraggio delle reti, Internet of Things, e middleware in generale.




Figura 2: Funzionamento di un Sistema CEP (High-Level) [3]

Come possiamo vedere dalla Figura 2, viene associata una semantica dettagliata agli elementi informativi da processare. Da una parte abbiamo gli **Event Observer**, i quali rappresentano la sorgente dei dati e degli eventi da notificare; in seguito abbiamo il **CEP Engine**, responsabile del filtraggio e della notifica degli eventi ai nodi *sink*, identificati come **Event Consumers** [3,8].

1.2 Sistemi di Raccomandazione

I sistemi di raccomandazione, raccolgono informazioni sulle preferenze di utente in corrispondenza di un insieme di elementi (ad esempio, film, musica, libri, giochi, viaggi, siti web, applicazioni, gadget). L'informazione può essere acquisita in maniera **esplicita** (tipicamente ciò viene fatto acquisendo il voto di un utente) o **implicitamente** (analizzando il comportamento dell'utente, ad esempio musica ascoltata, applicazioni scaricate, siti web visitati, libri letti). Inoltre i sistemi di raccomandazione, possono tener conto anche delle caratteristiche demografiche dell'utente (ad esempio età, nazionalità, sesso); dei contenuti informativi presenti nel mondo del Web 2.0, tipo quelli presenti all'interno dei Social Network, quali follower, followed, twit, like, post; dei dati provenienti dai dispositivi caratterizzanti l'Internet of Things (ad esempio, coordinate GPS, RFID, segnali medici inviati in real-time).

I sistemi di raccomandazione utilizzano diverse sorgenti informative al fine di fornire all'utente finale una migliore **Quality of Experience**, relativa alla predizione ed alla raccomandazione degli elementi che potrebbero interessargli. La tecnica del **Collaborative Filtering** (CF), ha un ruolo fondamentale nella raccomandazione, sebbene

viene spesso usata anche con altre tecniche di filtraggio basate sul contenuto o basate sulla conoscenza. Il CF si basa sulla cronologia decisionale dell'utente: oltre alle nostre esperienze, facciamo le nostre decisioni anche in base alla conoscenza che ci circonda.

Il processo con cui un sistema di raccomandazione generi una raccomandazione, è basato sulla combinazione delle seguenti considerazioni:

- 1. La tipologia di dati disponibili nel database (votazioni, informazioni di registrazione dell'utente, caratteristiche peculiari del contenuto informativo, relazioni sociali)
- 2. L'algoritmo di filtraggio usato (demografico, basato sul contenuto, collaborativo, basato sulle relazioni sociali, dipendente dal contesto e ibrido).
- 3. Il modello scelto (basato sull'uso diretto dei dati: 'memory-based', oppure un modello generato usando tali dati: 'model-based').
- 4. Le tecniche impiegate: approccio probabilistico, reti Bayesiane, algoritmi di tipo nearest neighbors, algoritmi genetici, reti neurali, logica fuzzy.
- 5. Livello di dispersione del database e scalabilità desiderata.
- 6. Capacità di elaborazione del sistema (tempo di elaborazione e consumi di memoria).
- 7. L'obiettivo da raggiungere (predizioni e raccomandazioni)
- 8. La qualità del risultato desiderata (ad esempio la precisione).

La ricerca nell'ambito dei sistemi di raccomandazione, richiede che i dati siano di dominio pubblico, al fine di semplificare la ricerca sulle tecniche innovative relative all'analisi dei dati. Esempi di dataset pubblici presenti in letteratura, sono Last.Fm, Delicious, Netflix, MovieLens. Le funzionalità interne per i sistemi di raccomandazione, sono caratterizzate dagli algoritmi di filtraggio. Gli algoritmi di filtraggio vengono classificati nel modo seguente:

- Collaborative Filtering
- Demographic Filtering
- Content-Based Filtering
- Hybrid Filtering

Il **Content-Based Filtering** consente di creare raccomandazioni basate sulle scelte fatte in passato da un utente (ad esempio, in un sito E-Commerce, se l'utente ha acquistato una fiction cinematografica, probabilmente il sistema di raccomandazione gli consiglierà una fiction recente, che non ha ancora acquistato sul sito). La tecnica consente inoltre di generare la raccomandazione utilizzando il contenuto dell'oggetto, ad esempio il testo, le immagini, l'audio.

Il **Demographic Filtering** si basa sul principio che gli individui con caratteristiche personali comuni, quali età, sesso, luogo di residenza e così via, avranno le stesse preferenze.

Il **Collaborative Filtering** consente agli utenti di attribuire un voto ad un insieme di elementi (filmati, canzoni, film, libri, all'interno di una piattaforma web) salvando le proprie preferenze all'interno di un database, e consentendo di creare una raccomandazione specifica per ogni utente. I voti degli utenti possono essere anche acquisiti in maniera implicita (ad esempio il numero delle volte che viene ascoltata una canzone, il numero delle consultazioni relative ad una risorsa). L'algoritmo utilizzato maggiormente per il Collaborative Filtering è il k Nearest Neighbors (kNN).

Nella versione "user to user", il KNN esegue i seguenti task per generare la raccomandazione:

- 1. Determinare i *k* utenti vicini all'utente corrente.
- 2. Implementare un approccio che tenga conto degli elementi "vicini" non ancora votati dall'utente corrente.
- 3. Estrarre le predizioni dal passo 2 e selezionare le N raccomandazioni.

La similarità può essere distinta in **item-item**: due elementi sono simili se tendono ad ottenere lo stesso rate dagli utenti; oppure **user-user**: due utenti sono simili se tendono a dare lo stesso rate agli elementi.

Uno dei problemi più noti del filtro collaborativo è il "*Cold Start*", che si potrebbe verificare nel caso in cui si considerano elementi che non sono stati votati in precedenza.

L'Hybrid Filtering è una combinazione di Collaborative Filtering e Demographic Filtering, oppure una combinazione tra Collaborative Filtering e Content-Based Filtering che sfrutta i pregi di ciascuna di queste tecniche. Il metodo è basato su metodi probabilistici come gli algoritmi genetici, genetica fuzzy, reti neurali, reti Bayesiane, clustering.

Inoltre possiamo suddividere i metodi in Memory-Based e Model-Based:

I **Memory Based** conservano in memoria le informazioni associate ad ogni utente, item o voto presente all'interno del sistema. Queste informazioni costituiscono la *Knowledge Base* sulla quale lavora l'algoritmo di predizione. Idealmente i sistemi di tipo memory based devono essere in grado di generare l'insieme di predizioni in maniera efficiente, processando tutte le informazioni contenute nella matrice *Utenti/Item*.

La matrice Utenti/Item definita all'interno del sistema di raccomandazione contiene entry i,j che rappresentano un voto dell'utente i-esimo per l'elemento j-esimo; nel caso in cui dovesse mancare una preferenza per un determinato item, il valore viene posto a 0.

$$M = \begin{bmatrix} i_1 & i_2 & \dots & i_j & \dots & i_m \\ u_1 & \dots & \dots & \dots & \dots \\ u_2 & \dots & \dots & \dots & \dots \\ \vdots & \vdots & \ddots & \dots & \dots \\ u_i & \dots & \dots & \dots & \dots \\ \vdots & \vdots & \vdots & \ddots & \dots \\ u_n & \dots & \dots & \dots & \dots \end{bmatrix}$$

Poiché i sistemi di raccomandazione sono caratterizzati da una elevata dimensione dello spazio degli utenti e degli item, il funzionamento degli algoritmi *memory-based* è stato definito sull'ipotesi di determinare un grado di similarità tra gli utenti, che permetta di estrapolare dalla matrice dei voti, le informazioni associate ai soli utenti simili dell'utente attivo.

I **Model Based**, utilizzano l'insieme dei voti espressi dagli utenti per costruire un modello statistico di preferenze su cui generare le predizioni.




Figura 3: Modelli di Raccomandazione [2]

E' utile citare i metodi di riduzione basati sulla Matrix Factorization, la tecnica model-based Latent Semantic Index (LSI), il metodo di riduzione Singular Value Decomposition (SVD) e le tecniche di clustering.

Nella Figura 3 viene illustrato un diagramma con le tecniche principali e gli algoritmi di raccomandazione maggiormente utilizzati in letteratura [2].

1.2.1 Metriche di Valutazione

La qualità di un sistema di raccomandazione può essere valutata dai risultati forniti in output. Le tipologie di metriche usate, dipendono dal tipo di CF utilizzato. Le metriche possono essere categorizzate in: **Predictive Accuracy**, come ad esempio il *Mean Absolute Error* (MAE) e sue varianti; **Classification Accuracy** metrics, come la *precision*, *recall*, *F1-measure*, e sensibilità *ROC*; **Rank Accuracy**, come il *Mean Average Precision*

(MAP). Desideriamo concentrarci sulla metrica **Root Mean Squared Error** (RMSE). Infatti la radice quadrata dell'errore quadratico medio, è una metrica molto utilizzata per la raccomandazione di film.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i,j} (p_{i,j} - r_{i,j})^2}$$

Nella seguente formula, n è il numero totale dei voti assegnati dagli utenti, $p_{i,j}$ è il voto predetto per l'utente i sull'elemento j, ed $r_{i,j}$ è il voto attuale. L'RMSE consente di valutare in maniera precisa i contributi degli errori assoluti tra i valori predetti ed i valori reali [11].

1.2.2 Introduzione alla Matrix Factorization

I modelli di **Matrix Factorization** possono essere utilizzati per ricercare quali sono i fattori latenti che caratterizzano le interazioni tra due tipologie di entità, tale che le interazioni user-item siano modellate come prodotti interni nello spazio. Ad esempio, due utenti potrebbero votare un determinato film con un voto alto, se ad entrambi piacciono gli attori, o il genere del film, ecc. Quindi, se si riescono a scoprire quali sono i fattori latenti dietro la scelta di un utente, si riesce anche a predire un voto o una possibile preferenza di un altro film rispetto all'utente. Ciò è possibile, perchè le feature associate all'utente dovrebbero convergere con le feature associate all'elemento.

Analizziamo la tecnica dal punto di vista matematico. Sia U l'insieme degli utenti, e sia D l'insieme degli elementi. Sia R la matrice dei voti assegnati dagli utenti agli elementi, di dimensione $|U| \times |D|$. Supponiamo di voler cercare i K fattori latenti. Innanzi tutto bisogna cercare le due matrici, P (una matrice $|U| \times K$) e Q (una matrice $|D| \times K$) tale che il loro prodotto sia una stima del tipo: $R \approx P \times Q^T = \hat{R}$. Ogni riga di P rappresenta il grado di associazione tra un utente e le feature, mentre ogni riga di Q tra un elemento e le feature. Al fine di poter calcolare la predizione di un rating su un elemento d_j votato dall'utente u_i , definiamo il prodotto interno tra i due vettori corrispondenti come:

$$\hat{r_{i,j}} = p_i^T q_j = \sum_{1}^{k} p_{ik} q_{kj}$$

Quindi un modo per ovviare a questo problema consiste nell'inizializzare le due matrici con alcuni valori, e calcolare la differenza tra i valori stimati ed i valori reali, e infine minimizzare questa differenza in maniera iterativa. Un metodo per minimizzare l'errore calcolato può essere l'algoritmo di discesa del gradiente stocastico oppure l'algoritmo **Alternating Least Squares** (ALS) [12].

In generale, mentre l'algoritmo della discesa del gradiente stocastico è più semplice e più veloce di ALS, ALS risulta essere preferibile in molteplici casi, tra cui la parallelizzazione computazionale. In ALS infatti, il sistema calcola ogni vettore d_j indipendentemente dagli altri elementi, così come accade per u_i . Ciò comporta un incremento del parallelismo a livello computazionale.

1.3 Introduzione al Data Stream Processing

Di recente, è nata una nuova classe di applicazioni *data-intensive*, nei quali i dati vengono modellati come relazioni transienti piuttosto che persistenti. Definiamo con il termine Data Stream, una sequenza di elementi codificati in digitale rappresentanti un'informazione. Esempi di applicazioni **Data Stream** vanno dal campo finanziario, monitoraggio del traffico di rete, applicazioni web, sicurezza, telecomunicazioni, gestione dati e reti di sensori. Nel modello Data Stream, i dati possono essere tuple relazionali, come ad esempio misurazioni di rete, registro chiamate, pagine web visitate, dati provenienti da sensori, e così via. Tuttavia, questi dati costituiscono un flusso multiplo e tempo variabile, tali da richiedere una nuova tecnologia al fine di poter esser gestiti.

Nei vari scenari applicativi sopra citati, non è efficiente e ne tanto meno semplice gestire i dati in arrivo, all'interno di un *Database Management System* (DBMS) tradizionale. Infatti, i DBMS tradizionali non sono progettati per trattare in maniera rapida un flusso di dati contiguo. Di conseguenza sono nati i **Data Stream Management System** (DSMS) in grado di gestire un flusso dati continuo. I DSMS sono in grado di offrire un'elevata flessibilità nell'eseguire query continue sullo stream dati. Poichè i DSMS sono data-driven, ogni qualvolta viene eseguita una query, essa produrrà nuovi risultati non appena arrivano nuovi dati da processare.




Figura 4: Architettura DSMS

I dati presenti all'interno di uno stream, arrivano online. Il sistema che elabora lo stream, non gestisce l'ordine di arrivo degli elementi da processare. Gli stream inoltre hanno la peculiarità di non avere una dimensione massima prefissata, poichè questa è altamente variabile. Il dato analizzato, può essere ulteriormente processato, o scartato, oppure archiviato all'interno di uno spazio di storage [1].

1.4 Il paradigma Publish-Subscribe

Il **Publisher/Subscribe** (pub/sub) è un design pattern, o uno stile architetturale, organizzato in modo che le entità comunicano tra loro in maniera asincrona.




Figura 5: Publish/Subscribe

I **publisher** inviano i messaggi utilizzando un canale di comunicazione denominato topic. I **subscriber** invece, si sottoscrivono ad un topic, al fine di ricevere tutti gli aggiornamenti di loro interesse, inviati dal publisher. Il sistema (vedi Figura 5) infatti ha il compito di distribuire i messaggi pubblicati dal publisher, a tutti i subscriber iscritti al topic. Infatti quando viene consegnato un nuovo messaggio su un determinato topic, ed un subscriber è iscritto a quest ultimo, il sub sarà notificato con un evento.

1.5 Il pattern Facade

Il design pattern **Facade**, è un pattern strutturale che consente di fornire un'interfaccia semplice ed unificata, la quale permette di accedere ai diversi sottosistemi dotati di interfacce complesse e diverse tra loro.




Figura 6: Diagramma UML del Pattern Facade

Le classi e gli oggetti definiti in questo pattern sono:

• Facade

 Conosce le classi relative al sottosistema che sono responsabili di una richiesta. - Delega le richieste del client all'oggetto del sottosistema appropriato.

Classi del sottosistema

- Implementa le funzionalità di un sottosistema.
- Gestisce i compiti assegnati dall'interfaccia Facade.
- Nasconde la complessità ed i dettagli realizzativi con l'oggetto Facade.

1.6 Il pattern Singleton

Il **Singleton** è un design pattern creazionale che ha lo scopo di garantire che di una determinata classe venga creata una ed una sola istanza, e di fornire un punto di accesso globale a tale istanza.

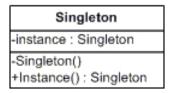


Figura 7: Diagramma UML del Pattern Singleton

Le classi e gli oggetti definiti in questo pattern sono:

Singleton

- Garantisce che un sistema istanzi un massimo di un oggetto di una classe.
- Consente al client di accedere all'unica istanza creata.

1.7 Il pattern Model-View-Controller (MVC)

Il pattern **Model View Controller** (MVC) è un pattern architetturale in grado di separare i dati dell'applicazione (contenuti nel Modello) dai componenti per la presentazione grafica (Vista) e la logica per l'elaborazione dell'input (Controllore).




Figura 8: Il pattern MVC

Model

- Contiene le funzionalità di base ed i dati.
- Incapsula lo stato dell'applicazione.
- Mostra le funzionalità dell'applicazione.
- Notifica alla View i cambiamenti.
- Risponde alle query sullo stato.

View

- Mostra le informazioni all'utente.
- Interpreta il Model.
- Richiede aggiornamenti dal Model.
- Consente al Controller di selezionare la View.

Controller

- Incapsula il comportamento dell'applicazione.
- Mappa gli input dell'utente agli aggiornamenti del Model.
- Seleziona la View dopo un input.

Separando il Model dalla View e dal Controller, si da la possibilità di associare più View allo stesso Model. Nel caso in cui l'utilizzatore modifica i dati contenuti nel Model mediante il Controller di una determinata View, tutte le altre View ricollegate a quel model ne propagano la variazione.

1.8 La tecnologia WebSocket

Il protocollo **WebSocket** standardizzato dall'IETF come **RFC 6455** consente la comunicazione bidirezionale e full duplex mediante una singola connessione TCP. La connessione persistente, viene instaurata mediante un sistema di handshaking client-key ed un modello di sicurezza origin-based. L'obiettivo di questa tecnologia è fornire un meccanismo per quelle applicazioni web-based che necessitano di comunicare con server che non consente di aprire connessioni HTTP multiple (ad esempio usando *XMLHttpRequest*, o <iframe>, o un sistema di *polling*), oppure per motivi di sicurezza per quei sistemi che bloccano l'utilizzo di porte non standard mediante firewall.




Figura 9: La tecnologia WebSocket

Il protocollo WebSocket viene inizializzato in primis con una fase di handshake e successivamente si procede con il trasferimento dati. Le porte di comunicazione utilizzate sono le stesse porte TCP di HTTP (80) e HTTPS (443). Inoltre vengono riutilizzati gli stessi elementi strutturali di HTTP, quali proxy ed autenticazione.




Figura 10: Architettura di WebSocket

Infine lo schema URI utilizzato è ws:// per connessioni in chiaro, wss:// per connessioni cifrate con TLS [4].

WebSocket viene utilizzato molto spesso per ottenere una comunicazione che sia a bassa latenza, efficiente e quasi realtime tra client e server. Vari scenari applicativi sono costituiti da giochi online multiplayer, chat, aggiornamento in tempo reale di informazioni ecc..

2 Soluzione proposta

2.1 La libreria Spark

Apache Spark è un sistema di cluster computing di tipo general-purpose, scalabile e veloce. Dispone di API di alto livello in **Java**, **Scala**, **Python** ed **R**, e un engine ottimizzato che supporta grafi di esecuzione generici. Integra inoltre un ampio set di tool come **Spark SQL** per structured data processing, **MLlib** per il machine learning e **Spark Streaming** per applicazioni streaming in tempo reale, descritti nelle sezioni successive. Spark è eseguibile sia su sistemi *Windows* che *UNIX-like* (Linux, Mac OS) [6].

Una delle possibili configurazioni di un sistema Spark è la modalità *cluster*, mostrata in Figura 11.




Figura 11: Configurazione in Spark di tipo Cluster Mode [6]

Le applicazioni Spark sono eseguite come un set di processi indipendenti sul cluster, coordinati dall'oggetto *SparkContext* del programma sorgente (detto **driver program**). Nel dettaglio, il driver può connettersi su diversi tipi di *cluster managers* (ad esempio un cluster di tipo Standalone, Mesos o YARN), il quale alloca le risorse a disposizione delle applicazioni. Una volta connesso, Spark scansiona i nodi del cluster alla ricerca degli **executor** (detti anche *worker node*), i quali eseguono effettivamente i task e il data storage delle applicazioni. A questo punto il driver invia il codice dell'applicazione agli executor (tipicamente un file JAR o Python incluso nello SparkContext) e schedula i task per l'esecuzione parallela [6].

Alcune considerazioni riguardo tale architettura sono:

• Ogni applicazione gestisce i propri worker, i quali restano attivi durante tutto il ciclo di vita, ed eseguono task multipli in thread multipli. Questo implica un isolamento tra le applicazioni, sia lato scheduling (ogni driver schedula i propri tasks) sia lato executor (tasks relativi ad applicazioni differenti risiedono in JVM differenti). Tuttavia ciò implica che non è possibile condividere nativamente i dati tra applicazioni diverse, a meno di utilizzare uno storage system esterno (ad esempio mediante *Apache Hadoop*).

- Il driver deve poter gestire le connessioni con i worker durante l'intero ciclo di vita dell'applicazione. Per questo motivo dev'essere sempre garantita la visibilità a livello di rete tra driver e worker durante l'esecuzione.
- È necessario che driver e worker abbiano, a livello di rete, una distanza relativamente breve, preferibilmente nella stessa LAN, affinché lo scheduling sia rapidamente eseguito [6].

Il principio di funzionamento di Spark, si basa sostanzialmente sul concetto di *Resilient Distributed Dataset* (**RDD**). Un RDD è una collezione di dati su cui è possibile operare parallelamente, ed è distribuita su tutti i nodi del cluster come file system Hadoop oppure è generata da una collezione esistente in Java o Scala [6].

Una seconda astrazione è rappresentata dalle variabili condivise (*shared variables*), utilizzate nelle computazioni parallele. Di default Spark tiene traccia delle variabili istanziate nei vari task, e consente se necessario di condividerle fra task, o fra task e driver. Le variabili condivise possono essere di due tipi: di tipo **broadcast**, il cui valore viene salvato nella cache per ogni nodo, e di tipo **accumulatore**, per esempio contatori o sommatori [6].

2.1.1 Spark Streaming

Spark Streaming, è un'estensione delle Core API di Spark per lo **stream processing**, di live data streams con throughput elevato. Supporta differenti sorgenti di data stream, come **Kafka**, Flume, Twitter, ZeroMQ, Kinesis o socket TCP, i quali possono essere processati tramite direttive come map, join, reduce e window. Nel post processing è possibile salvare i data stream in un file system, in un database o visualizzarli in una live dashboard. Come ulteriore fase nella pipeline delle operazioni, rientra anche il **machine learning** ed il graph processing. In Figura 12 viene riassunta l'architettura descritta [6].



Figura 12: Architettura di Spark Streaming [6]

Nello specifico, i data streams ricevuti vengono suddivisi in frammenti (*batches*), processati da Spark per generare lo stream finale risultante in batches, come mostrato in Figura 13 [6].



Figura 13: Spark Streaming Data Stream Processing [6]

Ad alto livello, il flusso continuo di dati è rappresento da una struttura astratta detta discretized stream o DStream, il cui contenuto è rappresentato da tutte le sorgenti collegate eventualmente con Spark, o da stream risultati da altri DStream. Internamente, un DStream è rappresentato tramite una sequenza di RDD [6].

2.1.2 Spark MLlib

Spark MLlib è la libreria per il machine learning di Spark, ed il suo obiettivo è di rendere l'uso di tali funzionalità semplice e scalabile. Comprende i più comuni algoritmi di learning quali classificazione, regressione, clustering, filtro collaborativo, riduzione dello spazio delle features, ecc. [6].

2.1.3 Spark SQL

Spark SQL è un modulo di Spark per il processing di dati strutturati. A differenza delle API RDD, la sua interfaccia consente di descrivere in maniera dettagliata la struttura e le operazioni da eseguire sui dati, in stile SQL. Le strutture astratte di riferimento per questo modulo sono i **Dataframes** e i **Datasets** [6].

Un **Dataframe** è un collezione distribuita di informazioni organizzata in colonne e attributi. Concettualmente è equivalente ad una tabella in un database relazionale, con caratteristiche aggiuntive fornite da Spark. In accordo con tale definizione sono presenti, oltre alle classiche funzionalità SQL, la creazione di DataFrame a partire da un RDD o un oggetto JSON e viceversa [6].

Un **Dataset** invece è un'interfaccia sperimentale introdotta nella versione 1.6 di Spark, mirata all'integrazione delle API RDD con l'engine SQL. Attualmente il supporto è limitato alle API Java e Scala [6].

2.2 Apache Kafka

Apache Kafka è un sistema di messaggistica di tipo publish-subscribe, orientato alla distribuzione. La sua architettura consente ad un singolo cluster di agire da backbone centrale per i dati di grandi organizzazioni. Gli stream, vengono partizionati e distribuiti lungo tutti i nodi del cluster, sfruttando la potenza di calcolo di ogni singola macchina. Di seguito si introduce la terminologia utilizzata in Kafka:

• Kafka organizza i flussi dei messaggi in categorie chiamate topics.

- I processi che si occupano di pubblicare i messaggi in Kafka sono chiamati producer.
- I processi che effettuano una sottoscrizione ad un topic ed elaborano i messaggi pubblicati sullo stesso sono chiamati *consumer*.
- I nodi all'interno del cluster(producer e consumer) sono coordinati da uno o più server chiamati *brokers* [5].

A livello concettuale il funzionamento di Kafka è riassunto in Figura 14. La comunicazione tra client e server avviene tramite protocollo TCP. Inoltre, sono presenti varie implementazioni del client Kafka, disponibili in vari linguaggi tra cui Java, Javascript e PHP [5].




Figura 14: Architettura di Apache Kafka [5]

Di seguito viene mostrata nel dettaglio la struttura di un topic in Figura 15. Per ogni topic, Kafka effettua un partizionamento dei messaggi in arrivo, tenendo traccia del loro ordine mediante un sistema di log [5].

Anatomy of a Topic




Figura 15: Struttura di un topic in Kafka [5]

Ogni partizione è una sequenza immutabile di messaggi, registrata e ordinata in un *commit log*. Ad ogni messaggio presente, viene assegnato un *id* sequenziale, detto *offset*, che identifica univocamente un messaggio nella relativa partizione [5].

Il cluster di Kafka conserva in memoria tutti i messaggi pubblicati, letti o non dai consumer, per un periodo di tempo configurabile. In pratica, il server registra dei metadati relativi ad ogni posizione del consumer nel log, chiamato appunto offset. Tale offset è fissato dal consumer, il quale può leggere i messaggi nell'ordine preferito [5].

2.2.1 Integrazione con Spark Streaming

Le API di Spark Streaming offrono la possibilità di configurare Kafka come sorgente di data stream, attraverso due possibili approcci [6].

Il primo approccio è detto **Receiver-based**, e consiste nell'implementazione di un Receiver tramite le API di Kafka. I dati ricevuti attraverso tale oggetto vengono memorizzati e processati nei worker node. Tuttavia, tale approccio potrebbe non garantire la consistenza in caso di *data loss*, ed è dunque necessario abilitare un meccanismo di integrità chiamato *Ahead Logs* [6].

Il secondo approccio, detto *Direct Approch* o *Receivers Less*, non prevede l'uso di Receiver, ma interroga periodicamente il server Kafka per rilevare il topic e la partizione aggiornata di recente, definendo in automatico la dimensione del batch di dati da processare. I vantaggi di questa tecnica sono:

- *Parallelismo semplificato*: Non è necessario creare ed unificare stream multipli di Kafka. Tramite la funzione *directStream*, Spark Streaming effettua un mapping tra le partizioni di Kafka in RDD, semplificandone l'elaborazione in parallelo.
- Efficienza: Il meccanismo Write Ahead Logs potrebbe generare problemi di duplicazione dei dati e relativi conflitti, nel momento in cui entrambe le istanze di Spark e Kafka tentino di risolvere una perdita di informazioni. Con un approccio diretto senza Receiver tale problema non sussiste [6].

2.3 Il framework Node.js

Node.js è un framework per la realizzazione di applicazioni web in Javascript lato server. La piattaforma è basata sul **Javascript Engine V8**, il runtime di Google utilizzato anche in Chrome, disponibile per le principali piattaforme, anche se maggiormente performante su sistemi operativi UNIX-like [7].



Figura 16: Il Framework Node.js

A differenza dei classici web server, che sfruttano un modello a processi concorrenti, Node.js utilizza una modalità di tipo *event-driven* per l'accesso alle risorse. Scrivere un'applicazione in Node.js dunque, consiste nel definire una serie di eventi che il sistema operativo deve monitorare, e all'attivazione degli stessi eseguire una funzione associata a tale evento, detta **callback**. Tale approccio definisce processi non bloccanti, evita il verificarsi di deadlocks, e in generale le operazioni di *I/O* non avvengono in maniera diretta. Ciò garantisce una maggiore **scalabilità** e **flessibilità** dell'architettura web [7].

All'interno del framework si ha a disposizione il package manager **npm**, tramite il quale è possibile installare moduli e librerie, gestire le diverse release, gli update e le dipendenze [7].

Il modulo **kafka.node** (https://www.npmjs.com/package/kafka-node) mette a disposizione un client in Node.js per la connessione ad un server Kafka. È possibile implementare sia il Producer che il Consumer, gestire gli eventi, creare topics, ecc. [7].

2.4 Angular.js

L'interfaccia dell'applicazione è stata realizzata attraverso il framework **AngularJS**, creando un modello MVC che sfrutta il two-way data binding di AngularJS [10].



Figura 17: Il Framework Angular.JS

Il front end è costruito grazie alla libreria **Bootstrap**, un framework che mira alla creazione di pagine web dinamiche, fluide e adattabili a qualsiasi dispositivo con differenti grandezze e risoluzione, che contiene una serie di modelli CSS, HTML e Javascript dei componenti web maggiormente utilizzati. Altre librerie utilizzate sono:

• Angular Route Una libreria che gestisce le view ed il routing in una macchina a stati.

Il layout contiene le seguenti directory:

• /css: Fogli di stile per le pagine HTML.

• /fonts: Web font.

• /img: Logo e immagini.

• /vendor: Librerie utilizzate dall'applicazione.

- /js: File Javascript della dashboard.
 - /controllers: Script dei controller di AngularJS.
 - /views: File HTML relativi alle view di AngularJS.
 - /services: Direttive di AngularJS per gli eventi associati al websocket.
- app. js: Script principale dell'applicazione. Al suo interno sono definiti gli stati con le relative view, le transizioni e le direttive associate ad ogni view per i relativi dati da visualizzare [10].

Per l'implementazione del WebSocket, la dashboard si avvale della libreria **Socket.IO**. Socket.io è una libreria Javascript per applicazioni web real time. Abilita una comunicazione di tipo bidirezionale tra client (generalmente eseguito nel browser) e server (applicazione Node.js). Principalmente il protocollo utilizzato è WebSocket, con un modello di esecuzione di tipo asincrono.

Per la visualizzazione dei dettagli relativi ai film, sia in fase di votazione che postraccomandazione, è stato utilizzato il servizio **OMDb API**, un web service che consente attraverso API REST di ottenere le informazioni sui film aggiornate dalla community.

3 Analisi e progettazione della soluzione proposta

3.1 Modello software

A livello software il modello proposto segue i principi del linguaggio di programmazione utilizzato, ovvero **Scala**.

Scala è un linguaggio multiparadigma, fortemente orientato alla programmazione ad oggetti e funzionale, che consente di definire i classici pattern software con una sintassi concisa ed elegante, secondo un principio di *type-safe*. In Figura 18 è mostrato lo schema delle classi utilizzate nell'applicazione, gli attributi ed i relativi metodi.




Figura 18: Classi dell'applicazione

In Scala, i metodi e le variabili non associate esplicitamente ad un'istanza di una classe, sono convertite in oggetti di tipo **Singleton**, e si definiscono tramite la keyword *object*.

Listato 1: Pattern Singleton in Scala

```
package test
object Blah {
   def sum(l: List[Int]): Int = 1.sum
}
```

Tali attributi e funzioni sono accessibili globalmente importando tale oggetto e richiamandole con una sintassi del tipo *test.Blah.sum*.

Di seguito sono descritte nel dettaglio le classi, i relativi attributi e metodi

- classe SparkCommons: Si occupa di inizializzare a livello globale il driver di Spark, settando l'indirizzo del master, il contesto per lo Streaming ed SQL, ed effettua il linking del JAR dell'applicazione nei nodi worker.
- classe KafkaCommons: Configura l'interfaccia verso il server Kafka, definendo la lista dei broker, dei topic ed inizializzando il Producer per la notifica delle raccomandazioni effettuate. Inoltre inizializza lo stream attraverso il metodo createDirectStream, il quale preleva i batches forniti da Spark Streaming ogni 30 secondi, aggiornati da una finestra di osservazione totale di 60 secondi.
- classe CEP: La classe CEP implementa il metodo hasEnoughVotes, il quale effettua il pattern matching sul DataFrame dall'aggregazione dei voti ricevuti nella finestra temporale. A seconda del numero di voti validi inseriti dall'utente e delle rules

prestabilite verrà visualizzata la relativa notifica sul driver di Spark. In caso di pattern positivo verrà eseguito il filtro collaborativo.

- classe CollaborativeFiltering: Questo oggetto si occupa di eseguire l'algoritmo ALS sul set di dati ricevuti. Il metodo userCF ha come parametri lo stream rating dell'utente, la lista dei ratings disponibili e la lista dei film. Il dataset dei ratings è suddiviso in set di training, validation e test (rispettivamente 60%, 20% e 20%). Al training set vengono aggiunti i voti dell'ultimo datastream ricevuto, ed il modello viene addestrato in diversi step provando diversi valori del numero di iterazioni, numero di fattori latenti e lambda. Ad ogni ciclo il metodo computeRmse effettua la predizione di n ratings per l'utente e calcola l'RMSE sul validation set. Dopo aver effettuato la validazione sul test set dell'RMSE, verrà utilizzato il modello con errore più basso per la predizione delle Top-N raccomandazioni, filtrando i ratings in modo tale da escludere i film che l'utente ha già votato. L'ultimo step è la serializzazione del risultato in formato JSON e l'invio dei dati sul topic creato dal server Kafka, svolto dal metodo out.
- classe FileParser: L'oggetto mette a disposizione i metodi parseRatings e parse-Movies, i quali utilizzando la funzione *textFile* dell'oggetto SparkContext effettuano il parsing dei file, definendo le strutture dati associate nel formato opportuno. In particolare, il parsing dei ratings avviene secondo un ordinamento decrescente in base al timestamp associato al voto.
- **classe Main**: La classe Main fornisce un'interfaccia per l'intera applicazione, avviando la pipeline di operazioni messe a disposizione dagli oggetti precedentemente descritti. Dopo aver inizializzato la lista dei file necessari, viene gestito il ciclo relativo alla lettura degli stream, check degli RDD, trasformazione in DataStream e verifica delle proprietà CEP. Esegue inoltre il trigger necessario per l'avvio dello stream, tramite la funzione *start()* di StreamingContext.

3.2 Architettura e Configurazione del sistema

In questa sezione viene descritta l'organizzazione fisica dell'architettura di sistema, gli attori in gioco ed i rispettivi ruoli e funzionalità. In Figura 19 è raffigurato il workflow tra i componenti ed il corrispettivo input/output.




Figura 19: Architettura del sistema

All'interno della web dashboard sono presenti due pagine, dalle quali è possibile rispettivamente effettuare le votazioni e visualizzare i risultati della raccomandazione. Esse interagiscono esclusivamente con Kafka tramite pubblicazione/sottoscrizione ai relativi topics, rendendo di fatto **trasparente** il flusso d'esecuzione sottostante.

Il modulo di Kafka, dunque, svolge effettivamente la funzione di **middleware** tra il livello applicativo e la parte di gestione dello stream. La sorgente di stream, pubblica i dati ricevuti verso il master di Spark, il quale smista l'elaborazione (funzionalità CEP e ALS) verso i worker disponibili.

L'ultimo passaggio riguarda la pubblicazione dei film raccomandati, verso il topic sul quale è collegata la pagina web in formato JSON, opportunamente monitorato da quest'ultima grazie alle Websocket.

Il sistema operativo utilizzato per l'implementazione della soluzione è stato **Ubuntu 15.10**. I nodi per testare la soluzione, sono dotati di configurazioni hardware eterogenee.

Suddividiamo in tre parti la configurazione relativa all'architettura del sistema.

• Configurazione di Apache Spark in Cluster Mode

In primis occorre scaricare Apache Spark (http://spark.apache.org/downloads.html). La versione utilizzata è stata la "Pre-built for Hadoop 2.6 and later". Dopo aver effettuato il download ed aver estratto il contenuto nella propria /home, creiamo una copia del file spark-env.sh.template chiamandolo spark-env.sh all'interno della directory conf della root di Spark. All'interno del file possiamo specificare varie direttive, ma per il nostro scopo settiamo quelle essenziali al corretto funzionamento:

Listato 2: spark-env.sh

```
export SPARK_WORKER_CORES=n
export SPARK_WORKER_MEMORY=mg
export SPARK_MASTER_IP=X.X.X.X
export SPARK_MASTER_PORT=7077
export MASTER=spark://${SPARK_MASTER_IP}:${SPARK_MASTER_PORT}
```

La variabile SPARK_WORKER_CORES, serve per poter configurare il numero di core da utilizzare sulla macchina (nel nostro caso settiamo il numero massimo di core che vogliamo utilizzare relativi ai nodi di tipo worker). La variabile SPARK_WORKER_MEMORY, consente di specificare quanta memoria dei rispettivi worker si desidera allocare per l'esecuzione del software (ad esempio 1000m, 2g). La variabile SPARK_MASTER_PORT, consente di specificare la porta sulla quale avviare il nodo Master. La variabile SPARK_MASTER_IP, per impostare l'indirizzo IP o l'hostname del nodo Master.

Dopo aver configurato il nodo Master, avviamolo dal terminale mediante /sbin/start-master.sh. Successivamente, avviamo i nodi Worker mediante /sbin/start-slave.sh spark://SPARK_MASTER_IP:SPARK_MASTER_PORT. Dal nodo Master, possiamo aprire il browser, digitando http://localhost:SPARK_MASTER_PORT in modo da visualizzare dalla Dashboard i Worker connessi ed i Job avviati nel sistema. Infine se il sistema non è configurato con hadoop, configurare i percorsi ed i relativi file anche sui worker.

• Configurazione di Apache Kafka

Come prima cosa occorre scaricare **Apache Kafka** (http://kafka.apache.org/downloads.html). La versione utilizzata è la **0.9.0.1** per **Scala 2.10**, quindi kafka_2.10-0.9.0.1. Dopo aver effettuato il download ed aver estratto il contenuto nella propria /home, apriamo il file server.properties all'interno della directory config della root di Spark.

All'interno del file, aggiungiamo le seguenti stringhe nel caso in cui non dovessero essere presenti:

Listato 3: server.properties

```
zookeeper.connect=localhost:2181
advertised.host.name=hostname/ip
```

La stringa zookeeper.connect=localhost:2181 consente di specificare i parametri di connessione nel formato hostname:port, dove host e port rappresentano rispettivamente l'hostname e la porta del server **ZooKeeper**. La stringa

advertised.host.name se settata, rappresenta l'hostname che verrà fornito ai broker, producer, e consumer per connettersi ad esso. Successivamente verranno illustrati quali sono le operazioni per creare i topic ed avviare il server Zookeeper da terminale.

• Configurazione del Framework Node.js

Dal terminale di Ubuntu, digitare sudo apt-get install nodejs, npm, per installare NodeJS, ed il gestore dei pacchetti per Javascript npm. Successivamente creiamo un link simbolico per node in questo modo sudo ln -s /usr/bin/nodejs /usr/bin/node. Accertiamoci inoltre con node -v che la versione di node sia la 5.10.1 (nel caso in cui la versione non dovesse essere questa, sarà necessario effettuare un ulteriore upgrade/downgrade). Dopo aver configurato l'ambiente di lavoro, è necessario effettuare il download della applicazione ed estrarla nella directory desiderata (ad esempio kafka_socket). Dal terminale, entrare all'interno della directory kafka_socket ed effettuare l'installazione di tutte le dipendenze richieste dall'applicazione mediante sudo npm install -g. Nel punto successivo, sarà illustrato come avviare l'applicazione Node.js [7].

• Avvio del Sistema

Lanciamo il seguente script dal terminale mediante sudo ./start.sh.

Listato 4: start.sh

```
#!/bin/bash
SCALA_VERSION = "2.10"
KAFKA_VERSION = "0.9.0.1"
#Directory Path of NodeJS Script
NODE_SCRIPT_DIR="kafka_socket"
#I supposed that Kafka Installation Directory is located in
   /home/<user>
KAFKA_HOME = $HOME / kafka_$SCALA_VERSION - $KAFKA_VERSION
#Start Zookeeper and Kafka Server as daemon
echo "Starting Zookeeper and Kafka Server..."
$KAFKA_HOME/bin/zookeeper-server-start.sh -daemon
   $KAFKA_HOME/config/zookeeper.properties
$KAFKA_HOME/bin/kafka-server-start.sh -daemon
   $KAFKA_HOME/config/server.properties
sleep 5
#Create Topics
echo "Creating LTopics..."
$KAFKA_HOME/bin/kafka-topics.sh --create --zookeeper
   localhost:2181 --replication-factor 1 --partitions 1 --topic
   votes
```

```
$KAFKA_HOME/bin/kafka-topics.sh --create --zookeeper
localhost:2181 --replication-factor 1 --partitions 1 --topic
result

#Start node.js App
echo "Starting_App_on_localhost:3000"
node $HOME/$NODE_SCRIPT_DIR/app.js --port 3000
```

Lo script è stato realizzato per automatizzare la configurazione dell'ambiente di lavoro. Leggendo lo script si intuisce che sia Zookeeper che Kafka Server vengono lanciati come demoni. Inoltre i topic creati mediante kafka-topics.sh presente all'interno della cartella bin della root di Kafka sono rispettivamente: votes, result. Il primo topic viene utilizzato per inviare i voti degli utenti, mentre il topic result, per fornire i risultati derivanti dal filtro collaborativo. Infine possiamo notare come l'applicazione Node.js venga avviata in locale sulla porta 3000.

4 Conclusioni e sviluppi futuri

Nel presente tema d'anno è stato realizzato un sistema di raccomandazione distribuito per film, in grado di attuare un filtro collaborativo sulla base di uno stream processing e funzionalità di tipo CEP legate al monitoring di tale flusso di dati, il tutto accessibile tramite interfaccia web.

Gli sviluppi futuri di tale progetto potrebbero riguardare la valutazione delle performance, la scelta di calcolatori più efficienti ed una possibile migrazione su piattaforma cloud.

Riguardo l'aspetto software e del machine learning, interessante è la possibilità di sperimentare nuovi algoritmi, tecniche per l'addestramento e la Matrix Factorization, in particolare per il filtro collaborativo basato su data stream.

Riferimenti bibliografici

- [1] Brian Babcock, Shivnath Babu, Mayur Datar, Rajeev Motwani, and Jennifer Widom. Models and issues in data stream systems. In *Proceedings of the Twenty-first ACM SIGMOD-SIGACT-SIGART Symposium on Principles of Database Systems*, PODS '02, pages 1–16, New York, NY, USA, 2002. ACM.
- [2] J. Bobadilla, F. Ortega, A. Hernando, and A. GutiéRrez. Recommender systems survey. *Know.-Based Syst.*, 46:109–132, July 2013.
- [3] Gianpaolo Cugola and Alessandro Margara. Processing flows of information: From data stream to complex event processing. *ACM Comput. Surv.*, 44(3):15:1–15:62, June 2012.
- [4] Ian Fette and Alexey Melnikov. The websocket protocol. 2011.
- [5] ApacheTM Software Foundation. Kafka Official 0.9.0 Documentation. http://kafka.apache.org/documentation.html, 2016.
- [6] ApacheTM Software Foundation. Spark Official 1.6.1 Documentation. http://spark.apache.org/docs/latest/, 2016.
- [7] Linux Foundation. Node.js Official Documentation. https://nodejs.org/en/docs/, 2016.
- [8] Lajos Jeno Fülöp, Gabriella Tóth, Róbert Rácz, János Pánczél, Tamás Gergely, Arpád Beszédes, and Lóránt Farkas. Survey on complex event processing and predictive analytics. *Nokia Siemens Networks*, 2010.
- [9] Patrick Gantet Patrick Gantet. Complex event processing.
- [10] Google. Angular.js Official Documentation. https://docs.angularjs.org/guide, 2016.
- [11] Xiaoyuan Su and Taghi M. Khoshgoftaar. A survey of collaborative filtering techniques. *Adv. in Artif. Intell.*, 2009:4:2–4:2, January 2009.
- [12] Gábor Takács, István Pilászy, Bottyán Németh, and Domonkos Tikk. Matrix factorization and neighbor based algorithms for the netflix prize problem. In *Proceedings of the 2008 ACM Conference on Recommender Systems*, RecSys '08, pages 267–274, New York, NY, USA, 2008. ACM.

5 Sorgenti

A Sorgenti Spark

Listato 5: Main.scala

```
package ml
import cep.CEP
import commons.{FileParser, KafkaCommons, SparkCommons}
import org.apache.log4j.{Level, Logger}
/**
* Qauthors Mauro Losciale and Pietro Tedeschi.
object Main {
def main(args: Array[String]): Unit ={
Logger.getLogger("org.apache.spark").setLevel(Level.ERROR)
Logger.getLogger("org.eclipse.jetty.server").setLevel(Level.OFF)
val ratings = FileParser.parseRatings()
val movies = FileParser.parseMovies()
val numRatings = ratings.count()
val numUsers = ratings.map(_._2.user).distinct().count()
val numMovies = ratings.map(_._2.product).distinct().count()
println("Got " + numRatings + " ratings from "
+ numUsers + " users on " + numMovies + " movies.")
val messages = KafkaCommons.kafkaDirectStreaming()
messages.foreachRDD { rdd =>
val votes = rdd.map(_._2)
val tableVotes = SparkCommons.sqlContext.read.option("header","true")
   .option("inferSchema","true")
   .json(votes).toDF().na.drop()
if (tableVotes.count() > 0) {
tableVotes.show()
tableVotes.registerTempTable("tableVotes")
val query = SparkCommons.sqlContext.sql("SELECT * FROM tableVotes WHERE rating
   > 3")
CEP.hasEnoughVotes(query, tableVotes, ratings, movies)
```

```
} else println("Nessun voto ricevuto")

}
SparkCommons.ssc.start()
SparkCommons.ssc.awaitTermination()
}
```

Listato 6: SparkCommons.scala

```
package commons
import org.apache.spark.sql.SQLContext
import org.apache.spark.streaming._
import org.apache.spark.{SparkConf, SparkContext}
* Handles configuration, context and so
* Cauthors Mauro Losciale and Pietro Tedeschi.
*/
object SparkCommons {
//build the SparkConf object at once
lazy val conf = {
new SparkConf(false)
.setMaster("local[*]")
.setAppName("Collaborative Filtering with Kafka")
.set("spark.logConf", "true")
}
lazy val sc = SparkContext.getOrCreate(conf)
lazy val ssc = new StreamingContext(sc, Seconds(30))
lazy val sqlContext = new SQLContext(sc)
sc.addJar("target/scala-2.10/mlspark-assembly-1.0.jar")
}
```

Listato 7: KafkaCommons.scala

```
package commons
import java.util.Properties
import kafka.producer.{Producer, ProducerConfig}
```

```
import kafka.serializer.StringDecoder
import org.apache.spark.streaming.Seconds
import org.apache.spark.streaming.kafka.{KafkaUtils, OffsetRange}
/**
* @authors Mauro Losciale and Pietro Tedeschi.
object KafkaCommons {
val kafkaTopics = "votes" // command separated list of topics
val kafkaBrokers = "makaveli-desktop:9092"
var offsetRanges = Array[OffsetRange]()
val kafkaParams = Map[String, String]("metadata.broker.list" ->
   kafkaBrokers
val topicsSet = kafkaTopics.split(",").toSet
val props:Properties = new Properties()
props.put("metadata.broker.list", "192.168.0.4:9092")
props.put("serializer.class", "kafka.serializer.StringEncoder")
val config = new ProducerConfig(props)
val producer = new Producer[String, String](config)
def kafkaDirectStreaming() = {
KafkaUtils.createDirectStream[String, String, StringDecoder,
   StringDecoder](
SparkCommons.ssc, kafkaParams, topicsSet).window(Seconds(60), Seconds(30))
}
```

Listato 8: CollaborativeFiltering.scala

```
*/
object CollaborativeFiltering {
def userCF(rdd: RDD[Rating], ratings: RDD[(Long, Rating)], movies:
   Map[Int, String]) = {
val myRatingsRDD = rdd
// split ratings into train (60%), validation (20%), and test (20%) based
// last digit of the timestamp, add myRatings to train, and cache them
val numPartitions = 4
val training = ratings.filter(x => x._1 < 6)</pre>
.values
.union(myRatingsRDD)
.repartition(numPartitions)
.cache()
val validation = ratings.filter(x \Rightarrow x._1 \Rightarrow 6 && x._1 < 8)
.repartition(numPartitions)
.cache()
val test = ratings.filter(x => x._1 >= 8).values.cache()
val numTraining = training.count()
val numValidation = validation.count()
val numTest = test.count()
println("Training: " + numTraining + ", validation: " + numValidation + ",
   test: " + numTest)
// train models and evaluate them on the validation set
val ranks = List(8, 12)
val lambdas = List(0.1, 10.0)
val numIters = List(10, 20)
var bestModel: Option[MatrixFactorizationModel] = None
var bestValidationRmse = Double.MaxValue
var bestRank = 0
var bestLambda = -1.0
var bestNumIter = -1
for (rank <- ranks; lambda <- lambdas; numIter <- numIters) {</pre>
val model = ALS.train(training, rank, numIter, lambda)
val validationRmse = computeRmse(model, validation, numValidation)
println("RMSE (validation) = " + validationRmse + " for the model trained
   with rank = "
```

```
+ rank + ", lambda = " + lambda + ", and numIter = " + numIter + ".")
if (validationRmse < bestValidationRmse) {</pre>
bestModel = Some(model)
bestValidationRmse = validationRmse
bestRank = rank
bestLambda = lambda
bestNumIter = numIter
}
}
// evaluate the best model on the test set
val testRmse = computeRmse(bestModel.get, test, numTest)
println("The best model was trained with rank = " + bestRank + " and
   lambda = " + bestLambda
+ ", and numIter = " + bestNumIter + ", and its RMSE on the test set is "
   + testRmse + ".")
// make personalized recommendations
val myRatedMovieIds = myRatingsRDD.map(_.product).collect().toSet
val candidates = SparkCommons.sc.parallelize(
  movies.keys.filter(!myRatedMovieIds.contains(_)).toSeq)
val recommendations = bestModel.get
.predict(candidates.map((0, _)))
.collect()
.sortBy(-_.rating)
.take(9)
out(recommendations, movies, KafkaCommons.producer)
}
/** Compute RMSE (Root Mean Squared Error). */
def computeRmse(model: MatrixFactorizationModel, data: RDD[Rating], n:
   Long): Double = {
val predictions: RDD[Rating] = model.predict(data.map(x => (x.user,
   x.product)))
val predictionsAndRatings = predictions.map(x => ((x.user, x.product),
   x.rating))
.join(data.map(x => ((x.user, x.product), x.rating)))
.values
math.sqrt(predictionsAndRatings.map(x \Rightarrow (x._1 - x._2) * (x._1 - x._2))
   x._2)).reduce(_ + _) / n)
}
/** Write recommendations array to a JSON file **/
def out(data: Array[Rating], film: Map[Int, String], producer:
```

Listato 9: CEP.scala

```
package cep
import ml.CollaborativeFiltering
import org.apache.spark.mllib.recommendation.Rating
import org.apache.spark.rdd.RDD
import org.apache.spark.sql.DataFrame
/**
* Qauthors Mauro Losciale and Pietro Tedeschi.
*/
object CEP {
def hasEnoughVotes(query: DataFrame, table: DataFrame, ratings:
   RDD[(Long,Rating)], movies: Map[Int, String]) = {
query.count() match {
  case c if c == 0 => println("Nessun voto valido")
  case c if c > 3 \Rightarrow
     val votesRating = table.map(v => Rating(0, v(0).toString.toInt,
         v(1).toString.toDouble))
     println("Make CF")
     CollaborativeFiltering.userCF(votesRating, ratings, movies)
  case c if c <= 3 => println("Voti validi inferiori a 4")
     }
  }
}
```

B Sorgenti Node.js

Listato 10: app.js

```
var vote_server = require('./lib/vote_server');
var kafka_consumer = require('./lib/kafka_consumer');
var kafka_producer = require('./lib/kafka_producer');
var http = require('http');
var express = require('express');
var path = require('path');
var argv = require('minimist')(process.argv.slice(2));
var favicon = require('serve-favicon');
var logger = require('morgan');
var methodOverride = require('method-override');
var bodyParser = require('body-parser');
var multer = require('multer');
var errorHandler = require('errorhandler');
var app = express();
// all environments
app.set('port', process.env.PORT || 3000);
app.use(favicon(__dirname + '/public/favicon.ico'));
app.use(logger('dev'));
app.use(methodOverride());
app.use(bodyParser.json());
app.use(bodyParser.urlencoded({ extended: true }));
app.use(multer());
app.use(express.static(path.join(__dirname, 'public')));
app.get('/', function (req, res) {
res.sendfile(__dirname + '/public/index.html');
});
if ('development' == app.get('env')) {
app.use(errorHandler());
}
var server = http.createServer(app);
var port = (argv.port) ? argv.port : 3000;
server.listen(port);
voteServer = vote_server(server);
var groupId = (argv.groupid) ? argv.groupid : 'vote-server-group';
kafkaConsumer = kafka_consumer(voteServer, groupId);
kafkaProducer = kafka_producer(voteServer);
if (process.platform === "win32") {
var rl = require("readline").createInterface({
input: process.stdin,
output: process.stdout
});
```

```
rl.on("SIGINT", function () {
  process.emit("SIGINT");
});
}

process.on("SIGINT", function () {
  console.log('Shutting_down');
  kafkaConsumer.close();
  kafkaProducer.close();
  process.exit();
});
```

Listato 11: controllers/vote.js

```
'use ustrict';
angular.module('moviedash.controllers')
.controller('VoteController',
['$scope',
'voteService',
'$http',
'$rootScope',
'$routeParams',
'$location',
function (
$scope,
voteService,
$http,
$rootScope,
$routeParams,
$location) {
$scope.getOMDBinfo = function(){
angular.forEach($scope.movies, function(m){
if ($scope.voteMessage.movieid == m.movieid)
$http.get("http://www.omdbapi.com/?t=" + m.title)
.then(function(response){
$scope.details = response.data
console.log(response.data) });
})
$scope.pagename = function() { return $location.path(); };
$scope.formatLabel = function($model) {
var inputLabel = '';
angular.forEach($scope.movies, function(m){
if ($model == m.movieid)
inputLabel = m.title
})
return inputLabel
```

```
// console.log($scope.movies[1].title)
$http.get('movies.json')
.then(function(res){
$scope.movies = res.data;
});
$scope.result = [];
$scope.sendVote = function () {
if ($scope.voteMessage) {
var message = {
movieid: $scope.voteMessage.movieid,
rating: $scope.voteMessage.rating
};
voteService.emit('message', message);
$scope.voteMessage = '';
}
};
voteService.on('message', function (message) {
//$scope.messages.push(message);
if ($scope.result.length == 9) $scope.result = [];
$http.get("http://www.omdbapi.com/?t=" + message.title)
.then(function(response){
if(response.data.Response=="True")
$scope.result.push(response.data)
//console.log(response.data)
});
})
}]);
```